

信息熵与游程编码 RLC

压缩的本质,是把"你早就猜得到的东西"少写几个字。这一节先量化"意外程度"——信息熵,再看最朴素的一种去冗余手段:把连着重复的符号折叠成"个数 + 符号"。

直觉类比

天气预报说"明天太阳照常升起",你几乎没获得任何信息——因为它本来就必然发生。可要是说"明天下陨石",这条消息信息量极大,因为它太意外了。越不可能发生的事,一旦发生,携带的信息量越大——这就是自信息。把一个信源里所有符号的自信息按概率加权平均,就得到信息熵:它衡量"平均每个符号有多让人意外",也正好是无损压缩每个符号平均最少要花的比特数。

1. 四个核心定义

冗余 (Redundancy)

数据中"可以被预测、因而不需重复存储"的部分。压缩的本质就是去除冗余:时间冗余(视频帧间)、空间冗余(相邻像素)、频谱冗余(颜色分量间)、心理视觉冗余(人眼不敏感的细节)。RLC 攻击的是"连续重复"这种最直白的空间/时间冗余。

自信息 (Self-information)

单个符号 s_i 携带的信息量,定义为 $I(s_i) = -\log_2 p_i$,单位 bit。概率 p_i 越小,自信息越大;必然事件 $p=1$ 时自信息为 0。

信息熵 (Entropy)

信源 S 中每个符号的平均信息量: $\eta = \sum p_i \cdot I(s_i) = -\sum p_i \cdot \log_2 p_i$, 单位 bit/symbol。等概率分布时熵最大;某符号概率为 1 时熵为 0。


游程编码 (Run-Length Coding, RLC)

一种无损压缩:把一串连续重复的符号,替换成"重复次数 + 符号"这一个二元组。适合大片相同的数据(如传真、纯色区域)。

2. 自信息随概率怎么变

把 $I = -\log_2 p$ 代几个值进去,直觉马上清晰——概率减半,自信息就多 1 bit:

概率 P	自信息 $-\text{LOG}_2 P$ (BIT)	含义
1	0	必然事件,毫无信息
1/2	1	一次公平抛硬币
1/4	2	更少见,信息更多
1/8	3	越稀有越"值钱"
$\rightarrow 0$	$\rightarrow \infty$	几乎不可能,一旦发生信息量爆炸



红点即上表四行: p 每减半, 曲线就往上跳 1 bit


越稀有越"值钱"。自信息 $I = -\log_2 p$ 是一条随概率下降而陡升的曲线: $p=1$ (必然)时信息为 0, $p \rightarrow 0$ (几乎不可能)时信息爆炸到无穷。曲线的凹形正是"稀有事件信息量不成比例地大"的几何写照。

3. 为什么熵是无损压缩的下界

熵不是随便定义的数字,它是一道物理下限:任何无损编码,平均每个符号的码长 $\bar{l}$ 都不可能低于熵 η ,即 $\eta \leq \bar{l}$ 。

道理在于:要想缩短平均码长,就得给高概率符号短码、低概率符号长码。但码字不能随便短——任意无损前缀码受 Kraft 不等式约束 $\sum 2^{-l_i} \leq 1$ 。在这个约束下让加权平均码长 $\sum p_i \cdot l_i$ 最小,最优解恰好是 $l_i = -\log_2 p_i$,此时平均码长正好等于熵。

可现实里码长必须是整数(Huffman 就是逐符号给整数位码),没法精确取到 $-\log_2 p_i$ 这种小数,所以只能 $\bar{l} \geq \eta$,并且最优时满足 $\eta \leq \bar{l} < \eta + 1$ 。这也解释了后面为什么算术编码(对整条消息编码、能逼近熵)常常胜过 Huffman。一句话:熵 = 消除每个符号平均不确定性所需的最少比特数。



两端 $\eta=0$ (某符号必然出现, 毫无悬念), 中点 $\eta=1$ (五五开, 最不可预测)


为什么"等概率时熵最大"。以只有两个符号的信源为例, 横轴是符号 A 出现的概率。当 $p=0$ 或 1 时结果完全确定, 熵为 0 , 压无可压; 当 $p=0.5$ 时最难猜, 熵达到峰值 1 bit ——这正是熵作为压缩下界的含义: **越可预测的数据, 理论上能压得越狠**。RLC 正是靠"大片重复=极可预测"这一端吃到红利。

例题 A · 计算信息熵

信源 $S = \{a, b, c\}$, 概率 $P = \{0.5, 0.25, 0.25\}$ 。求熵 η 。

- ① 写出公式: $\eta = -\sum p_i \cdot \log_2 p_i$ 。
- ② 逐项算自信息: $-\log_2 0.5 = 1$, $-\log_2 0.25 = 2$, $-\log_2 0.25 = 2$ 。
- ③ 按概率加权求和: $\eta = 0.5 \times 1 + 0.25 \times 2 + 0.25 \times 2$ 。
- ④ 算出: $\eta = 0.5 + 0.5 + 0.5 = 1.5$ 。

结果: $\eta = 1.5 \text{ bit/symbol}$ 。作对比: 若用等长定长码, 3 个符号要 $\lceil \log_2 3 \rceil = 2 \text{ bit/symbol}$ ——熵告诉我们理论上平均只需 1.5 bit , 还有压缩空间。



同一信源:定长码要 2.0 bit,熵只要 1.5 bit

熵 = 可压缩的地板。 例题 A 的信源用最笨的定长码要 2 bit/符号,而熵告诉我们理论下界是 1.5 bit/符号——中间这 0.5 bit 就是变长编码(下一课的 Huffman)能榨出的压缩空间。注意:谁也压不到 1.5 以下,那是物理地板。



例题 B · 游程编码 RLC

对字符串 aaabbc 做 RLC 编码,并算压缩效果。

- 1 从左到右扫描,统计每段连续相同符号的长度: aaa (3 个 a)、bb (2 个 b)、c (1 个 c)。
- 2 把每段写成 (次数, 符号): (3,a) (2,b) (1,c)。
- 3 对比长度:原始 6 个符号 → 编码后 3 个二元组。

结果: aaabbc → (3,a)(2,b)(1,c)。

提醒:RLC 只在重复多时才划算。若是 abcabc 这种毫无连续重复的串,RLC 反而会把 6 个符号变成 6 个二元组,越"压"越大——这正是它的边界情况。



同色=一段连续相同符号,各折叠成"(次数, 符号)"

RLC 就是"数个数再折叠"。从左到右扫描,把每一段连续相同的符号压成一个二元组。aaabbc 的三段分别折成 (3,a)(2,b)(1,c)。重复越长,折叠收益越大;但若像 abcabc 毫无连续重复,每段长度都是 1,反而越折越长——这就是 RLC 的适用边界。

自测题 1

字母表 $S = \{a, b, c, d\}$, 概率 $P = \{1/2, 1/4, 1/8, 1/8\}$ 。该信源的熵 η 是多少 bit/symbol?

- A. 2.00
- B. 1.75
- C. 1.50
- D. 2.25

▼ 答案与解释

答案:B 1.75

自信息分别为

$-\log_2(1/2)=1$ 、 $-\log_2(1/4)=2$ 、 $-\log_2(1/8)=3$ 、 $-\log_2(1/8)=3$ 。

加权求和: $\eta = 1/2 \times 1 + 1/4 \times 2 + 1/8 \times 3 + 1/8 \times 3 = 0.5 + 0.5 + 0.375 + 0.375 = 1.75$ 。

解题套路:凡是 $1/2^n$ 这种概率,自信息就是整数 n ,不用查对数表,心算即可。

自测题 2

对字符串 WWWBWBWB 做游程编码,正确结果是?

- A. (5,W)(2,B)(1,W)(3,B)
- B. (4,W)(2,B)(1,W)(3,B)
- C. (5,W)(3,B)(3,B)
- D. (W,5)(B,2)(W,1)(B,3)

▼ 答案与解释

答案:A (5,W)(2,B)(1,W)(3,B)

分段: WWW = 5 个 W、 BB = 2 个 B、 W = 1 个 W、 BBB = 3 个 B。合起来 (5,W)(2,B)(1,W)(3,B)。

B 项:数错了,W 是 4 个不是 5 个;C 项:漏掉了中间那个单独的 W,把两段 B 错误合并;D 项:本题约定"次数在前、符号在后",顺序写反。

易错点:中间夹的单个符号也必须单独成一段,不能和前后同类符号合并。

下一步 → 熵给出了"最少要花多少 bit"的理论下界,但没告诉我们**具体怎么给每个符号分配码字**去逼近它。进入 [0009 · Shannon-Fano 与 Huffman 编码](#),学两种把高频符号编成短码的变长编码算法。