

Shannon-Fano 与 Huffman 编码

熵告诉你"理论上最少需要多少比特",而 Huffman 告诉你"实际怎么逼近它"。这一节把最高频的计算题拆到骨头里:亲手搭一棵 Huffman 树,算出平均码长,再和熵掰一掰手腕。

直觉类比

想象你要给一群人起代号,而且要用摩尔斯电码那样的"点划串"喊出来。经常叫到的人(高频)你会给他一个短代号,难得出现一次的人给个长代号——这样平均下来喊得最省力。但有个坑:如果"张三 = 01",而"李四 = 011",那听到 011 你会先误判成张三。前缀码就是那条铁律:没有任何一个代号是另一个代号的开头,于是一串比特流从左往右读,能被唯一切开、绝不含糊。变长编码要省比特,又不能歧义,答案就是"按频率分配长度的前缀码"。

1. 核心定义

前缀码 (Prefix Code / 前缀无关码)

任何一个码字都不是另一个码字的前缀。因此比特流无需分隔符即可被唯一解码。*Huffman* 码天然满足此性质——这正是它被机器解码的根基。

Shannon-Fano 编码 (自顶向下 top-down)

先按频率排序,再递归地把符号集切成两半(两半的频率之和尽量相等),一半标 0、一半标 1,直到每份只剩一个符号。*结果不错,但不保证最优。*

Huffman 编码 (自底向上 bottom-up)

反复挑出两个最小频率合并成一棵子树,父节点频率 = 两子之和,插回队列保持有序;重复到只剩一个根。左枝标 0、右枝标 1,从根到叶的路径即码字。*可证明是"最小冗余码"——给定概率模型下最优。*

平均码长 (Average Code Length)

$\bar{l} = \sum p_i \cdot l_i$, 即每个符号出现概率 p_i 乘其码字长度 l_i 再求和,单位是"比特/符号"。这就是计算题最终要求的那个数。

熵 (Entropy)


$\eta = - \sum p_i \cdot \log_2 p_i$, 信源每符号所含的平均信息量,是无损编码平均码长的理论下界。

2. 两种算法对比

选择题常问"哪种是自底向上""哪种保证最优",记住下表即可秒选:

维度	SHANNON-FANO	HUFFMAN
构造方向	自顶向下(先分裂整体)	自底向上(先合并最小)
核心操作	把集合切成频率近似相等的两半	取两个最小频率合并成子树
是否前缀码	是	是
是否最优	否(接近但不保证)	是(最小冗余码)
码字唯一性	不唯一(切分/标号可变)	不唯一(左右标号、并列频率次序可变)
应用	早期,已被取代	JPEG、MPEG、传真机等

提醒:"Huffman 码不唯一"是常见陷阱题——0/1 标在哪条枝、并列概率谁先合并都可以变,但平均码长 $\bar{L}$ 唯一确定。所以计算题最终对答案的是 $\bar{L}$,不是具体码字。




3. 为什么变长编码能省比特

若用定长码给 6 个符号编码,每个都要 $\lceil \log_2 6 \rceil = 3$ 比特,不论它多常见。变长编码的思路是:让高频符号占短码、低频符号占长码,用概率给码长"加权"。只要频率分布不均匀,加权平均后的 $\bar{l}$ 就能低于定长码。

但省到什么程度有极限。Shannon 证明了无损编码的平均码长不可能低于熵 η ;而 Huffman 作为最优前缀码,能把 $\bar{l}$ 卡进一个窄区间:

$$\eta \leq \bar{l} < \eta + 1$$

下界 η 是信息论极限,达不到更低;上界 $\eta+1$ 保证 Huffman 最多比理论值多浪费不到 1 比特/符号。编码效率 = $\eta / \bar{l}$,越接近 1 越好。这条不等式是简答题和验算的黄金标尺。



定长码 3.0 $\rightarrow$ Huffman 2.35,已贴到熵地板 2.28,只差 0.07 bit

Huffman 有多接近理论极限?同一信源:最笨的定长码要 3.0 bit/符号;Huffman 压到 2.35,离熵地板 2.28 仅 0.07 bit,编码效率 97%。绿色虚线是熵——信息论规定的物理地板,任何无损编码都压不破。 $\eta \leq \bar{l} < \eta+1$ 这条不等式,就是在说"红柱永远落在绿线和绿线+1 之间"。

题目:信源有 6 个符号,概率分布如下。请构建 Huffman 编码,给出各码字,计算平均码长 $\bar{l}$,并与熵 η 比较、求编码效率。

符号	A	B	C	D	E	F
概率 p_i	0.40	0.20	0.15	0.10	0.10	0.05

- ① 升序排列。把 6 个概率从小到大排好,便于每次取最小两个:
 $F(0.05) < D(0.10) = E(0.10) < C(0.15) < B(0.20) < A(0.40)$
- ② 合并第 1 次:取最小两个 $F(0.05)$ 与 $D(0.10) \rightarrow$ 父节点
 $[FD]=0.15$ 。
 当前队列: $E(0.10), C(0.15), [FD](0.15), B(0.20), A(0.40)$
- ③ 合并第 2 次:最小两个是 $E(0.10)$ 与 $C(0.15) \rightarrow$ 父节点
 $[EC]=0.25$ 。
 当前队列: $[FD](0.15), B(0.20), [EC](0.25), A(0.40)$
- ④ 合并第 3 次:最小两个 $[FD](0.15)$ 与 $B(0.20) \rightarrow$ 父节点
 $[FDB]=0.35$ 。
 当前队列: $[EC](0.25), [FDB](0.35), A(0.40)$
- ⑤ 合并第 4 次:最小两个 $[EC](0.25)$ 与 $[FDB](0.35) \rightarrow$ 父节点
 $[ECFDB]=0.60$ 。
 当前队列: $A(0.40), [ECFDB](0.60)$
- ⑥ 合并第 5 次(收尾): $A(0.40)$ 与 $[ECFDB](0.60) \rightarrow$ 根 = 1.00。树建成。
- ⑦ 赋码(左枝 0、右枝 1,从根到叶读路径)。约定每次合并中先取的较小节点为 0 枝、较大节点为 1 枝:
 - 根: $A = 0$, 子树 $[ECFDB] = 1$
 - $[ECFDB]$ 下: $[EC] = 10$, $[FDB] = 11$
 - $[EC]$ 下: $E = 100$, $C = 101$
 - $[FDB]$ 下: $[FD] = 110$, $B = 111$
 - $[FD]$ 下: $F = 1100$, $D = 1101$

符号	概率 P_i	码字	码长 L_i
A	0.40	0	1
B	0.20	111	3
C	0.15	101	3
E	0.10	100	3
D	0.10	1101	4
F	0.05	1100	4

验证前缀性:没有任何码字是另一个的开头(如 0 之后不再有以 0 开头的码),解码无歧义。

8 算平均码长 $\bar{l} = \sum p_i \cdot l_i$:


$$\begin{aligned}\bar{l} &= 0.40 \times 1 + 0.20 \times 3 + 0.15 \times 3 + 0.10 \times 3 + 0.10 \times 4 + 0.05 \times 4 \\ &= 0.40 + 0.60 + 0.45 + 0.30 + 0.40 + 0.20 = 2.35 \text{ 比特/符号}\end{aligned}$$

9 算熵 $\eta = -\sum p_i \cdot \log_2 p_i$ (用 $\log_2 0.4 \approx 1.322$, $\log_2 0.2 \approx 2.322$, $\log_2 0.15 \approx 2.737$, $\log_2 0.1 \approx 3.322$, $\log_2 0.05 \approx 4.322$):

$$\begin{aligned}\eta &= 0.4 \times 1.322 + 0.2 \times 2.322 + 0.15 \times 2.737 + 2 \times (0.1 \times 3.322) + 0.05 \times 4.322 \\ &\approx 0.529 + 0.464 + 0.411 + 0.664 + 0.216 \approx 2.28 \text{ 比特/符号}\end{aligned}$$

10 比较并验算。检验不等式 $\eta \leq \bar{l} < \eta + 1$: $2.28 \leq 2.35 < 3.28$ ✓。编码效率 = $\eta / \bar{l} = 2.28 / 2.35 \approx 97\%$ 。

结论:Huffman 码字如上表,平均码长 $\bar{l} = 2.35$ 比特/符号,熵 $\eta \approx 2.28$,满足 $\eta \leq \bar{l} < \eta + 1$,编码效率约 **97%**——比定长码的 3 比特省了约 22%,且逼近理论极限。



酒红圆=符号叶子(内为字母,上为概率,下为码字);米色圆=合并节点(内为频率和);绿 0 / 红 1 = 左右分枝

这就是例题那棵树。从根往下每走一步读一位:向左记 0、向右记 1,走到叶子即得码字。**叶子越深 = 码字越长 = 概率越小**——A(0.40)紧贴根只 1 位,F(0.05)沉到最底要 4 位。这正是"高频短码、低频长码"的几何形态;也一眼看出为何前缀无关:所有符号都在叶子上,谁也不在谁的路径中途。

自测题

某信源有 5 个符号,概率为 A:0.4, B:0.3, C:0.1, D:0.1, E:0.1。请构建 Huffman 树,计算其平均码长 $\bar{L}$ 。下列哪个结果正确?

- A. $\bar{L} = 1.9$ 比特/符号
- B. $\bar{L} = 2.1$ 比特/符号
- C. $\bar{L} = 2.3$ 比特/符号
- D. $\bar{L} = 2.5$ 比特/符号

▼ 答案与解释

答案:B $\bar{L} = 2.1$ 比特/符号

建树(每次合并最小两个):

- ① 升序: C(0.1), D(0.1), E(0.1), B(0.3), A(0.4)
- ② 合并 C(0.1)+D(0.1)=[CD]0.2 → 队列 E(0.1), [CD]0.2, B(0.3), A(0.4)
- ③ 合并 E(0.1)+[CD]0.2=[ECD]0.3 → 队列 B(0.3), [ECD]0.3, A(0.4)
- ④ 合并 B(0.3)+[ECD]0.3=0.6 → 队列 A(0.4), 0.6
- ⑤ 合并 A(0.4)+0.6=1.0,根建成。

赋码(左0右1): A=0 (1位)、 B=10 (2位)、 E=110 (3位)、 C=1110 (4位)、 D=1111 (4位)。

平均码长: $\bar{L} = 0.4 \times 1 + 0.3 \times 2 + 0.1 \times 3 + 0.1 \times 4 + 0.1 \times 4 = 0.4 + 0.6 + 0.3 + 0.4 + 0.4 = 2.1$ 比特/符号。

验算: 熵 $\eta \approx 2.05$, 满足 $2.05 \leq 2.1 < 3.05$ ✓。注意:即便你把 0/1 标号或并列合并次序换一换,码字会变,但 $\bar{L}$ 仍是 2.1——所以选 B。

下一步 → 进入 [0010 · 自适应 Huffman 编码](#):当信源概率事先未知、要边读边编时,Huffman 树如何动态生长与调整。

