

CBIR:语义鸿沟 · 全局 vs 局部 · SIFT

给机器看两张图片,它怎么知道"这两个是同一件商品"?答案不是理解画面的含义,而是把图片翻译成一串数字(特征),再用距离量出它们像不像。这一讲拆开这条流水线的前半段。

直觉类比

你想在超市里找"和手机里这张照片一样的酸奶"。你不会去比较两瓶酸奶的"意义",而是比对可见的线索:瓶子的颜色分布、标签上的花纹、瓶盖的形状。计算机也一样——它把每张图压成一组可比较的数字(特征向量),再算两组数字之间的距离:距离越小,越像。整个"基于内容的检索"就建立在这个朴素想法上。而计算机永远看不懂"这是酸奶"这层含义,这道跨不过去的坎就叫语义鸿沟。

1. 为什么需要 CBIR:语义鸿沟


早期图像搜索靠人工打文本标签("狗""日落""红色")。但标签有两个致命问题:一张图内容太丰富,几个词说不清(意图鸿沟);而且计算机存的只是像素值,它根本不"理解"这些像素合起来是"一只狗"。这就把问题推到了基于内容的检索。

基于内容的多媒体检索 (CBIR, Content-Based Image Retrieval)

以用户提供的样例图像/视频/音频作为查询条件(**Query by Example**),系统自动提取内容特征,查找库中含有相同或相似内容的多媒体数据。区别于靠文字标签匹配的传统搜索。典型应用:商品检索、地标识别、视频拷贝检测与版权保护。


语义鸿沟 (Semantic Gap)

计算机能提取的底层视觉特征(颜色、纹理、形状等像素级信息)与人类对图像的高层语义理解("这是一只在草地上奔跑的狗")之间存在的鸿沟。这是 CBIR 要突破的核心难题:两张语义相同的图(同一只狗的不同照片)底层特征可能差很远,两张语义无关的图底层特征却可能很近。



语义鸿沟。上层是人一眼看懂的**含义**,下层是机器唯一能拿到的**像素级数字**。CBIR 的全部难处在于:两图语义相同(同一只狗)底层特征可能差很远,语义无关的两图特征却可能很近——这道裂缝跨不过去。怎么读:全局/局部特征、SIFT 都是在**底层这一侧**努力,尽量让"特征距离近"逼近"语义相似",但永远无法真正到达上层。

CBIR 系统框架:离线阶段把库图像逐张做**特征提取** → **建索引**;在线阶段把查询图像做**特征提取** → **特征匹配** → **返回结果**。三大关键技术:特征提取、特征匹配、高维索引。这一讲聚焦前两者的地基——特征长什么样、怎么算距离。



CBIR 检索流程。 查询图 → 提取特征(变成向量) → 与特征库里每条特征算距离 → 按距离升序返回最相似的图。怎么读: 特征库是离线预先建好的(虚线), 在线只做"查询图提特征 + 比距离 + 排序"。这就是为什么 CBIR 是相似性检索(返回一个排好序的列表)而非数据库那样的精确命中。

2. 两种特征: 全局 vs 局部

把图片翻译成数字有两条思路: 要么给整幅图算一个总的描述(全局), 要么在图里挑一批显著的小点各算一个描述(局部)。

全局特征 (Global Feature)


从整幅图像抽取的底层视觉特征, 主要有颜色、纹理、形状三类。最典型的例子是颜色直方图——统计整幅图里每种颜色出现了多少像素, 得到一个描述"这张图整体是什么色调"的向量。计算简单、速度快。软肋: 无法应对遮挡、裁剪等"图像攻击", 一旦局部被挡住或裁掉, 整幅图的统计量就变了, 难以保持不变性。

局部特征 (Local Feature)

从图像中具有代表性和显著性的局部结构(角点、斑点、区域)抽取的视觉不变量。先由检测子(Detector)找到这些特征点的位置, 再由描述子(Descriptor)把每个点周围的图案编码成向量。理想的局部特征应满足: 鲁棒性、区分性、提取的高效性。因为只看局部, 即使图片被部分遮挡或裁剪, 没被破坏的那些点依然能匹配上。

维度	全局特征	局部特征
描述对象	整幅图算一个向量	图中多个显著点,各算一个向量
代表	颜色直方图、纹理、形状	Harris 角点、SIFT、SURF、MSER
计算成本	低,快	高,特征点多(SIFT 约 3000 个)
抗遮挡/裁剪	差——局部变化污染整体统计	好——未受损的点仍可匹配
不变性	弱	强(视具体算法可抗旋转/尺度/仿射)

一句话记忆:颜色直方图是全局特征的招牌;它简单但脆,挡一半就崩。局部特征贵,但抗打击。



3. 局部特征检测子:Harris vs SIFT/SURF

局部特征的第一步是"在哪儿设点"。**Harris** 是最经典的角点检测子:把一个小窗口在图上朝任意方向挪,若灰度都发生明显变化,说明这是个角点(平坦区怎么挪都不变,边缘只有垂直边缘方向挪才变)。它用图像微分矩阵 M 的角点响应函数 $R = \det(M) - k \cdot \text{trace}(M)^2$ ($k \approx 0.04 \sim 0.06$)来打分。

但 Harris 有个要命的短板:不具有尺度不变性。同一个角,把图放大后,原来的小窗口再也框不住整个角结构,Harris 就检测不到它了。**SIFT/SURF** 正是为解决问题而生——它们在高斯尺度空间里同时搜索位置和尺度上的极值,所以图片缩放后依然能找到同一个特征点。

特性	HARRIS 角点	SIFT / SURF
特征类型	角点	斑点(blob,尺度空间极值)
光照不变	是	是
旋转不变	是	是
尺度不变	否(单尺度)	是(尺度空间搜索)
仿射不变	否	否(仅 MSER 抗仿射)
速度	快、简单	SIFT 慢(1~2s);SURF 是 SIFT 的 3~5 倍
对噪声	对模糊/噪声敏感	较鲁棒

补充:给 Harris 套上尺度空间搜索就得到 **Harris-Laplace**,它就具备了尺度不变性——可见"尺度不变"这条性质来自尺度空间机制,而非角点本身。


SIFT:为什么是 128 维

SIFT (Scale-Invariant Feature Transform)

Lowe 于 1999 年提出、2004 年完善的局部特征检测子 + 描述子。检测端在高斯差分金字塔(**DoG**)的尺度空间中检测局部极值作为特征点(用 DoG 近似 LoG 以减少计算量);描述端把特征点邻域旋转到主方向后做 **4×4** 分块、每块统计 **8** 个方向的梯度直方图,得到 **4 × 4 × 8 = 128** 维特征向量。优点:抗旋转 + 抗尺度、独特性强。缺点:维数高、匹配代价大、实时性差、不抗仿射。

记住这条推导链而不是死记数字:**4×4** 个空间小块 × 每块 **8** 个梯度方向 = **128**。常见陷阱是把它记成 $4 \times 8 = 32$,或误以为 128 是"字节数"。作为对比,SURF 描述子是 **4×4** 分块 × 每块 4 种 Haar 统计量 = **64** 维,一半大小,所以更快。


① 关键点 + 主方向



邻域内每像素的梯度 → 定主方向

先把邻域旋转到主方向 → 抗旋转

② 4×4 分块 · 每块 8 方向



$4 \times 4 \times 8 = 128$ 维

每个小格统计 8 个方向的梯度直方图

SIFT 描述子:为什么是 128 维。①先在特征点邻域用所有像素的梯度定出**主方向**,把邻域转正(这样图旋转了描述子不变)。②再把邻域划成 $4 \times 4 = 16$ 个小块,每块统计 **8 个方向**的梯度直方图,拼起来正好 $4 \times 4 \times 8 = 128$ 维。怎么记:陷阱是记成 $4 \times 8 = 32$,或把 128 当"字节数"——它是**16 块 × 8 方向**的维度。SURF 同样 4×4 分块但每块只取 4 个 Haar 统计量,故 64 维、更快。

4. 如何计算两张图的相关性:特征 + 距离度量

这是真题简答题常问的"如何计算图像之间的相关性(相似性)"。答案是两步走,不要只答一半:

简答答题框架:图像间相似性怎么算

- ① **特征提取**——把每张图转成可比较的特征向量(全局用颜色直方图等;局部用 SIFT/SURF 等)。这一步把"图像"翻译成"数字",是能比较的前提。
- ② **距离度量**——定义一个距离函数 $d(x,y)$ 计算两个特征向量的差别;距离越小越相似。CBIR 是相似性检索而非文本那样的精确匹配,所以必须靠距离来量化"像不像"。常用 L1(曼哈顿)、L2(欧氏)、余弦距离、马氏距离等。

结论:相关性 = 用合适的特征把图像向量化,再用合适的距离函数量出向量间的差异。答简答题时这两步都要写全。

一个"合格"的距离函数不是随便定义的,它必须满足四条数学性质(这也是选择/判断题的常客):

性质	公式	直觉
非负性	$d(x, y) \geq 0$	距离不可能是负的
同一性	$d(x, x) = 0$	自己和自己距离为 0
对称性	$d(x, y) = d(y, x)$	A 到 B 与 B 到 A 一样远
三角不等式	$d(x, k) + d(k, y) \geq d(x, y)$	绕道 k 只会更远,不会更近

把它和之前学的失真度量(Lo7)对照:那里用距离衡量"压缩后与原图的误差",这里用距离衡量"两张图内容像不像"——同一套数学工具,升级到了语义层的应用。得到距离后,常再套一个高斯核 $e^{(-d^2/2\sigma^2)}$ 把"距离"翻译成 0~1 的"相似度"。

自测题 1 · 特征辨析

下列关于全局特征与局部特征的说法,错误的是?

- A. 颜色直方图是一种全局特征,从整幅图像统计得到
- B. Harris 角点检测子具有尺度不变性,图像放大后仍能检测到同一角点
- C. SIFT 描述子是 128 维,来自 4×4 分块每块 8 个方向
- D. 局部特征比全局特征更能抵抗遮挡和裁剪

▼ 答案与解释

答案:B

Harris 不具有尺度不变性——它是单尺度检测子,图像缩放后原窗口框不住角结构,就检测不到了。抗尺度的是 SIFT/SURF/MSER/Harris-Laplace。A(颜色直方图=全局特征)、C(SIFT 128 维= $4 \times 4 \times 8$)、D(局部特征抗遮挡)都正确。

陷阱:凡见到"Harris 抗缩放/抗尺度"一律判错;Harris 只抗旋转和光照。

在 CBIR 中,"语义鸿沟(Semantic Gap)"最准确的含义是?

- A. 不同图像格式(JPEG/PNG)之间难以互相转换的问题
- B. 计算机能提取的底层视觉特征与人类的高层语义理解之间的差距
- C. 查询图像分辨率与库图像分辨率不一致带来的匹配误差
- D. 特征向量维度过高导致索引速度慢的问题

▼ 答案与解释

答案:B

语义鸿沟指底层视觉特征(颜色/纹理/形状等像素级信息)与人类高层语义理解("这是一只狗")之间的落差:两张语义相同的图特征可能差很远,语义无关的图特征却可能很近。它是 CBIR 要突破的核心难题。A 是格式问题、D 是索引效率(高维索引解决)、C 只是预处理细节,都不是语义鸿沟。

易混:"意图鸿沟"指用户查询意图难用文本标签表达,和语义鸿沟并列但不同,别混为一谈。

下一步 → 特征算出来、距离量完了,还要回答一个问题:检索系统到底"准不准"?进入 [0020 · 检索性能评价:查全率·查准率·mAP](#),拆解那道压轴计算题。