

[复习主页](#) · [真题与考点](#) · [课程计划](#)

CNN 基础:卷积 · 池化 · 输出尺寸计算

上一讲我们手工设计特征(边缘、角点、SIFT);这一讲把"设计特征"这件苦差交给网络自己去学。整门课的最后一块拼图,也是计算题里最好拿分的一类——套公式即可。

直觉类比

L11 里我们像老工匠:亲手雕出"该看哪里"的模板(梯度、SIFT 描述子),再拿去匹配。**CNN** 则像招进一批学徒——你不告诉它边缘长什么样,只给它成千上万张带标签的图和一个"错了就挨罚"的损失函数,它自己反复调整卷积核,直到底层学出边缘、中层学出纹理、高层学出"猫脸""车轮"。特征不再靠人拍脑袋,而是从数据里长出来的。

1. 三种积木:卷积层 · 池化层 · 全连接层

一个典型 CNN 就是这三种层交叉堆叠而成。先把每种积木的定义钉死:

卷积层 (Convolutional Layer)

用一个小的卷积核 / 滤波器(如 3×3) 在输入图上滑动, 逐位置做加权求和, 产出一张特征图 (**feature map**)。两大法宝: 局部关联(每个输出只连接输入的一小片)与参数共享(同一个核扫遍全图)——正是这两点把全连接网络"参数爆炸→过拟合"的病治好了。 *stride* 步长、 *padding* 填充、 *depth* 通道数是它的三个旋钮。

池化层 (Pooling Layer)


对特征图做下采样, 只保留主要特征。 **Max pooling** 取窗口最大值, **Average pooling** 取平均。作用: 减少参数与计算量、防止过拟合、提升泛化。池化没有可学参数——它只是缩图。

全连接层 (Fully Connected Layer)


相邻两层所有神经元两两相连, 通常位于网络尾部, 把提炼好的特征映射到类目得分。整张网里参数量通常最大的就是它——VGG 的 138M 参数大多堆在这。

感受野 (Receptive Field)

某个输出神经元"能看到"的原始输入区域大小。越往深层, 单个神经元的感受野越大, 看到的東西越"全局"。这就是为什么小卷积核多层堆叠能覆盖大范围——深度换视野。



卷积: 核在输入上滑动, 一次算出输出一个像素。把 3×3 卷积核对准输入左上角的红框区域(它"看到"的这一小片就是**感受野**), 核里 9 个权重与框内 9 个数**逐元素相乘再求和**, 得到输出图左上角那一个像素(图中的 ?)。核向右滑一格 (stride=1) 算下一个, 滑遍全图就得到整张 3×3 输出。无填充 (pad=0) 时输出比输入小: $(5-3)/1+1=3$ 。整张图只用这一个核的同一套权重——这就是**参数共享**。



2. 四座里程碑:经典网络对比

选择题与简答题常考"哪个网络先提出了什么"。记住下面这张纵向演进表——核心线索是越来越深、参数越来越省:

网络 (年份)	层数	参数量	关键特点
AlexNet (2012)	8 层 (5 卷积 + 3 全连 接)	~60M	深度学习翻身之作;首用 ReLU 、 Dropout 、数据增强、双 GPU;top-5 错误率骤降约 10 个百分点。
VGG (2014)	16–19 层	138M (大多在 FC 层)	结构极简:全用 3×3 小卷积核堆叠加深;证明"深度"本身有用。参数最臃肿。
GoogleNet (2014)	22 层 (含池化 27 层)	~AlexNet 的 1/12	Inception 模块多尺度卷积;1×1 卷积降维省算力;去掉 FC 层;辅助分类器缓解梯度消失。
ResNet (2015)	152 层	— (除输出无 FC)	残差连接 (shortcut):学"变化量"而非全量,使超深网络可训练;top-5 错误率降到 3.57%。

3. CNN 为什么能"自动学特征"

回到 L11 的对比。手工特征(SIFT、HOG、颜色直方图)的流程是:人先定义"什么算特征"→提取→再喂给分类器。它的天花板由设计者的想象力决定,而且换个任务就得换一套特征。

CNN 把"特征提取"与"分类"合并成一条可端到端训练的管道。浅层卷积核自动收敛到边缘/颜色检测器,深层组合出物体部件——这套层级表示不是人写死的,而是被损失函数(交叉熵、MSE 等)一路反向传播"逼"出来的。数据越多、网络越深,它能学到的抽象层次越高。这就是为什么 2012 年 AlexNet 一出,手工特征时代基本落幕。

代价也很清楚:CNN 是数据饥渴且算力昂贵的黑箱,可解释性远不如手工特征。考试里问"CNN 相比传统方法的优势/代价",答这两点即可。

4. 两条必背公式

计算题的全部分数都藏在这两条式子里,务必背到条件反射:

① 卷积输出尺寸

设输入边长 N 、卷积核边长 F 、填充 p 、步长 s ,则输出特征图边长:

$$\text{输出} = (N + 2p - F) / s + 1$$


无 padding 时 $p = 0$,退化为 $(N - F)/s + 1$ 。结果须为整数,否则说明尺寸/步长不匹配。

② 卷积层参数量

设卷积核 $F \times F$ 、输入通道数 C 、卷积核个数(输出通道) K ,则:

$$\text{参数量} = (F \cdot F \cdot C + 1) \cdot K$$

那个 $+1$ 是每个卷积核自带的一个偏置 **bias**。输出通道数 = 卷积核个数 K 。



$$0 = \lfloor (W-K+2P)/S \rfloor + 1 = \lfloor (5-3+2)/2 \rfloor + 1 = 3$$

把公式每一项对上图:输出边长 $0 = \lfloor (W-K+2P)/S \rfloor + 1$ 。灰格是两侧各补的 padding P,中间 5 个是原始输入宽 W;红框是核宽 $K=3$ 首次覆盖的位置,金色箭头是它每次向右跳的步长 $S=2$ 。核在"加了 padding 的 $W+2P=7$ 格"上滑动,每步跳 S,能落几次就出几个像素: $(7-3)/2+1=3$ 。怎么读:先算分子 $W-K+2P$,再除步长 S,最后才 +1(算头一次落点)。边界:结果要向下取整 $\lfloor \cdot \rfloor$,除不尽说明核在边缘"够不着",最后一步被舍掉。

例题 · 输出尺寸 + 参数量一起算

输入图像 $32 \times 32 \times 3$ (高×宽×通道),用 10 个 5×5 的卷积核,步长 $s=1$,填充 $p=2$ 。求输出特征图尺寸与该卷积层参数量。

- ① 列出已知: $N=32$, $F=5$, $p=2$, $s=1$,输入通道 $C=3$,卷积核个数 $K=10$ 。
- ② 套公式①算输出边长: $(N + 2p - F)/s + 1 = (32 + 2 \times 2 - 5)/1 + 1 = (32 + 4 - 5) + 1 = 31 + 1 = 32$ 。
- ③ 拼上通道:输出通道数 = 卷积核个数 = 10,故输出特征图为 $32 \times 32 \times 10$ 。(padding=2 恰好把尺寸"撑回"原大小,这也是 $p=(F-1)/2$ 保持同尺寸的常用技巧。)
- ④ 套公式②算参数量:每个核 $5 \times 5 \times 3 = 75$ 个权重,加 1 个偏置 = 76;共 10 个核。
- ⑤ 合计: $(5 \times 5 \times 3 + 1) \times 10 = 76 \times 10 = 760$ 个参数。

结论:输出特征图 $32 \times 32 \times 10$;该卷积层参数量 760。注意参数量与输入图多大无关(参数共享),这正是卷积省参数的根源。

自测题

某卷积层输入为 7×7 , 卷积核 3×3 , 步长 $s=2$, 填充 $p=1$ 。输出特征图的边长是多少?

- A. 3
- B. 4
- C. 5
- D. 6

▼ 答案与解释

答案: B 4

直接代入公式①: $(N + 2p - F)/s + 1 = (7 + 2 \times 1 - 3)/2 + 1 = (7 + 2 - 3)/2 + 1 = 6/2 + 1 = 3 + 1 = 4$ 。

易错点: 先算分子 $7+2-3=6$, 再除以步长 **2** 得 3, 最后才 **+1** 得 4。若忘记 padding(当 $p=0$) 会算成 $(7-3)/2+1=3$, 恰好落入干扰项 A——所以务必看清题目给没给 padding。

全课完 → 12 讲微课到此收官——从像素、色彩、音频、压缩编码, 一路到检索与 CNN。接下来别再单点练了, 去做**整卷自测**: 先用 真题与考点 核对每类计算题的老师口径, 再上 模拟卷 掐表实战一遍。祝你稳过这 100 分。