

[复习主页](#) · [真题与考点](#) · [课程计划](#)

CNN 基础:卷积 · 池化 · 输出尺寸计算

上一讲我们手工设计特征(边缘、角点、SIFT);这一讲把"设计特征"这件苦差交给网络自己去学。整门课的最后一块拼图,也是计算题里最好拿分的一类——套公式即可。

直觉类比

L11 里我们像老工匠:亲手雕出"该看哪里"的模板(梯度、SIFT 描述子),再拿去匹配。**CNN** 则像招进一批学徒——你不告诉它边缘长什么样,只给它成千上万张带标签的图和一个"错了就挨罚"的损失函数,它自己反复调整卷积核,直到底层学出边缘、中层学出纹理、高层学出"猫脸""车轮"。特征不再靠人拍脑袋,而是从数据里长出来的。

1. 三种积木:卷积层 · 池化层 · 全连接层

一个典型 CNN 就是这三种层交叉堆叠而成。先把每种积木的定义钉死:

卷积层 (Convolutional Layer)

用一个小的卷积核 / 滤波器(如 3×3) 在输入图上滑动, 逐位置做加权求和, 产出一张特征图 (**feature map**)。两大法宝: 局部关联(每个输出只连接输入的一小片) 与 参数共享(同一个核扫遍全图)——正是这两点把全连接网络"参数爆炸→过拟合"的病治好了。 *stride* 步长、*padding* 填充、*depth* 通道数是它的三个旋钮。

池化层 (Pooling Layer)


对特征图做下采样, 只保留主要特征。**Max pooling** 取窗口最大值, **Average pooling** 取平均。作用: 减少参数与计算量、防止过拟合、提升泛化。池化没有可学参数——它只是缩图。

全连接层 (Fully Connected Layer)


相邻两层所有神经元两两相连, 通常位于网络尾部, 把提炼好的特征映射到类目得分。整张网里参数量通常最大的就是它——VGG 的 138M 参数大多堆在这。

感受野 (Receptive Field)

某个输出神经元"能看到"的原始输入区域大小。越往深层, 单个神经元的感受野越大, 看到的東西越"全局"。这就是为什么小卷积核多层堆叠能覆盖大范围——深度换视野。



卷积: 核在输入上滑动, 一次算出输出一个像素。把 3×3 卷积核对准输入左上角的红框区域(它"看到"的这一小片就是**感受野**), 核里 9 个权重与框内 9 个数**逐元素相乘再求和**, 得到输出图左上角那一个像素(图中的 ?)。核向右滑一格(*stride*=1)算下一个, 滑遍全图就得到整张 3×3 输出。无填充(*pad*=0)时输出比输入小: $(5-3)/1+1=3$ 。整张图只用这一个核的同一套权重——这就是**参数共享**。



池化:把每个 2×2 窗口压成一个值,只留主特征。输入按 2×2 划成四块,**Max pooling** 每块取最大值:左上块 {1,3,5,6}→6 ,右上 {2,4,7,8}→8 ,左下 {3,2,1,0}→3 ,右下 {1,2,4,3}→4 。4×4 一步降为 2×2 ,尺寸减半。若换成 **Average pooling** 就把"取最大"改成"取平均"。池化**没有可学参数**,纯粹是缩图——目的是减计算、防过拟合、增强对微小平移的鲁棒性。

2. 四座里程碑:经典网络对比

选择题与简答题常考"哪个网络先提出了什么"。记住下面这张纵向演进表——核心线索是越来越深、参数越来越省:

网络 (年份)	层数	参数量	关键特点
AlexNet (2012)	8 层 (5 卷积 + 3 全连 接)	~60M	深度学习翻身之作;首用 ReLU 、 Dropout 、数据增强、双 GPU;top-5 错误率骤降约 10 个百分点。
VGG (2014)	16–19 层	138M (大多在 FC 层)	结构极简:全用 3×3 小卷积核堆叠加深;证明"深度"本身有用。参数最臃肿。
GoogLeNet (2014)	22 层 (含池化 27 层)	~AlexNet 的 1/12	Inception 模块多尺度卷积; 1×1 卷积降维省算力;去掉 FC 层;辅助分类器缓解梯度消失。
ResNet (2015)	152 层	— (除输出无 FC)	残差连接 (shortcut):学"变化量"而非全量,使超深网络可训练;top-5 错误率降到 3.57%。

3. CNN 为什么能"自动学特征"

回到 L11 的对比。手工特征(SIFT、HOG、颜色直方图)的流程是:人先定义"什么算特征"→提取→再喂给分类器。它的天花板由设计者的想象力决定,而且换个任务就得换一套特征。

CNN 把"特征提取"与"分类"合并成一条可端到端训练的管道。浅层卷积核自动收敛到边缘/颜色检测器,深层组合出物体部件——这套层级表示不是人写死的,而是被损失函数(交叉熵、MSE 等)一路反向传播"逼"出来的。数据越多、网络越深,它能学到的抽象层次越高。这就是为什么 2012 年 AlexNet 一出,手工特征时代基本落幕。

代价也很清楚:CNN 是数据饥渴且算力昂贵的黑箱,可解释性远不如手工特征。考试里问"CNN 相比传统方法的优势/代价",答这两点即可。

4. 两条必背公式

计算题的全部分数都藏在这两条式子里,务必背到条件反射:

① 卷积输出尺寸

设输入边长 N 、卷积核边长 F 、填充 p 、步长 s , 则输出特征图边长:

$$\text{输出} = (N + 2p - F) / s + 1$$


无 padding 时 $p = 0$, 退化为 $(N - F) / s + 1$ 。结果须为整数, 否则说明尺寸/步长不匹配。

② 卷积层参数量

设卷积核 $F \times F$ 、输入通道数 C 、卷积核个数(输出通道) K , 则:

$$\text{参数量} = (F \cdot F \cdot C + 1) \cdot K$$

那个 $+1$ 是每个卷积核自带的一个偏置 **bias**。输出通道数 = 卷积核个数 K 。



$$O = \lfloor (W - K + 2P) / S \rfloor + 1 = \lfloor (5 - 3 + 2) / 2 \rfloor + 1 = 3$$

把公式每一项对上图: 输出边长 $O = \lfloor (W - K + 2P) / S \rfloor + 1$ 。灰格是两侧各补的 padding P , 中间 5 个是原始输入宽 W ; 红框是核宽 $K=3$ 首次覆盖的位置, 金色箭头是它每次向右跳的步长 $S=2$ 。核在"加了 padding 的 $W+2P=7$ 格"上滑动, 每步跳 S , 能落几次就出几个像素: $(7-3)/2+1=3$ 。怎么读: 先算分子 $W-K+2P$, 再除步长 S , 最后才 $+1$ (算头一次落点)。边界: 结果要向下取整 $\lfloor \cdot \rfloor$, 除不尽说明核在边缘"够不着", 最后一步被舍掉。

例题 · 输出尺寸 + 参数量一起算

输入图像 $32 \times 32 \times 3$ (高 $\times$ 宽 $\times$ 通道),用 10 个 5×5 的卷积核,步长 $s=1$,填充 $p=2$ 。求输出特征图尺寸与该卷积层参数量。

- ① 列出已知: $N=32$, $F=5$, $p=2$, $s=1$, 输入通道 $C=3$, 卷积核个数 $K=10$ 。
- ② 套公式①算输出边长: $(N + 2p - F)/s + 1 = (32 + 2 \times 2 - 5)/1 + 1 = (32 + 4 - 5) + 1 = 31 + 1 = 32$ 。
- ③ 拼上通道: 输出通道数 = 卷积核个数 = 10, 故输出特征图为 $32 \times 32 \times 10$ 。(padding=2 恰好把尺寸"撑回"原大小,这也是 $p=(F-1)/2$ 保持同尺寸的常用技巧。)
- ④ 套公式②算参数量: 每个核 $5 \times 5 \times 3 = 75$ 个权重,加 1 个偏置 = 76; 共 10 个核。
- ⑤ 合计: $(5 \times 5 \times 3 + 1) \times 10 = 76 \times 10 = 760$ 个参数。

结论: 输出特征图 $32 \times 32 \times 10$; 该卷积层参数量 760。注意参数量与输入图多大无关(参数共享),这正是卷积省参数的根源。

自测题

某卷积层输入为 7×7 , 卷积核 3×3 , 步长 $s=2$, 填充 $p=1$ 。输出特征图的边长是多少?

- A. 3
- B. 4
- C. 5
- D. 6

▼ 答案与解释

答案: B 4

直接代入公式①: $(N + 2p - F)/s + 1 = (7 + 2 \times 1 - 3)/2 + 1 = (7 + 2 - 3)/2 + 1 = 6/2 + 1 = 3 + 1 = 4$ 。

易错点: 先算分子 $7+2-3=6$, 再除以步长 **2** 得 3, 最后才 **+1** 得 4。若忘记 padding(当 $p=0$) 会算成 $(7-3)/2+1=3$, 恰好落入干扰项 A——所以务必看清题目给没给 padding。

5. 更多计算例题: 五种常考题型

上面那道是"尺寸+参数一起算"的标准型。下面按考试常见的五种变体各来一道, 每道都把套公式的顺序写死。做题口诀: 先分子 $N-F+2p$, 再除步长 s , 最后才 **+1**; 除不尽向下取整。

例题 2 · 无填充卷积(尺寸会缩小)

输入 28×28 , 卷积核 5×5 , 步长 $s=1$, 不填充($p=0$)。求输出边长。

- 1 已知 $N=28$, $F=5$, $p=0$, $s=1$ 。
- 2 代公式①: $(N - F + 2p)/s + 1 = (28 - 5 + 0)/1 + 1 = 23 + 1 = 24$ 。

输出 24×24 。无填充时,核在边缘"够不着",每条边各丢 $F-1=4$ 个像素 → 尺寸从 28 缩到 24。这正是 VGG 要靠 $p=1$ 补回尺寸的原因。

例题 3 · 池化的输出尺寸

输入特征图 24×24 , 做 2×2 最大池化, 步长 $s=2$ 。求输出边长。

- 1 池化沿用同一条尺寸公式,但几乎总是无填充($p=0$): 输出 $= (N - F)/s + 1$ 。
- 2 代入 $N=24$, $F=2$, $s=2$: $(24 - 2)/2 + 1 = 22/2 + 1 = 11 + 1 = 12$ 。

输出 12×12 , 尺寸减半。记住: $F=2$ 、 $s=2$ 的池化就是"边长除以 2"。池化不改变通道数,也没有参数——只缩高宽。


例题 4 · 多层串联,追踪特征图尺寸(大题最爱)

输入 32×32 , 依次经过: **Conv1**(5×5 , $p=2$, $s=1$) $\rightarrow$ **Pool1**(2×2 , $s=2$) $\rightarrow$ **Conv2**(3×3 , $p=1$, $s=1$) $\rightarrow$ **Pool2**(2×2 , $s=2$)。求最终特征图边长。

关键纪律: 一层一层来, 上一层的输出就是下一层的输入。列一张表最不容易错:

层	操作	输入	算式	输出
Conv1	5×5 , $p2$, $s1$	32	$(32 - 5 + 4)/1 + 1$	32
Pool1	2×2 , $s2$	32	$(32 - 2)/2 + 1$	16
Conv2	3×3 , $p1$, $s1$	16	$(16 - 3 + 2)/1 + 1$	16
Pool2	2×2 , $s2$	16	$(16 - 2)/2 + 1$	8

最终 **8×8** 。规律看得很清楚: 带 $p=(F-1)/2$ 的卷积保持尺寸不变(5×5 配 $p2$ 、 3×3 配 $p1$), 真正让特征图变小的是池化(每次减半: $32 \rightarrow 16 \rightarrow 8$)。所以数"缩了几次", 基本就是数"经过几个 $\text{stride}=2$ 的池化"。



卷积(配 padding)保尺寸 · 池化 $\text{stride}=2$ 是尺寸减半的唯一推手

尺寸逐层追踪流水线。五个方块是每一步后的特征图,大小按边长画: $32 \rightarrow 32 \rightarrow 16 \rightarrow 16 \rightarrow 8$ 。**蓝红两次 Conv** 都因为配了 $p=(F-1)/2$ 而**尺寸不变**(只在换特征、加通道);**两次 Pool($s=2$)** 各把边长**砍半**。所以"最终多大"的答案,几乎只由**经过几个 $\text{stride}=2$ 的下采样**决定——本例两次, $32 \rightarrow 16 \rightarrow 8$ 。**做题提醒:**一层写一行,上一行输出填进下一行输入,绝不跳步心算。

例题 5 · ALEXNET 首层的大步长卷积

AlexNet 输入 $227 \times 227 \times 3$, 第一层用 96 个 11×11 卷积核, 步长 $s=4$, $p=0$ 。求输出特征图尺寸。

- 1 代公式①: $(227 - 11 + 0)/4 + 1 = 216/4 + 1 = 54 + 1 = 55$ 。
- 2 输出通道 = 卷积核个数 = 96, 故输出 $55 \times 55 \times 96$ 。

输出 $55 \times 55 \times 96$ 。大步长($s=4$)是"一上来就猛缩图"的手段:一步就把 227 压到 55。有的教材写成 224×224 配 $p=2$, 则 $\lfloor (224-11+4)/4 \rfloor + 1 = \lfloor 54.25 \rfloor + 1 = 55$, 靠向下取整同样得 55。

例题 6 · 全连接层的参数量(看它为何最臃肿)

某网络最后一张特征图为 $7 \times 7 \times 512$, 把它展平后接一个 4096 个神经元的全连接层。求这一层的参数量。

- 1 展平: $7 \times 7 \times 512 = 25088$ 个输入。
- 2 全连接=每个输出神经元与所有输入相连, 各带 1 个偏置: 参数 = 输入数 $\times$ 输出数 + 输出数 = $25088 \times 4096 + 4096$ 。
- 3 计算: $= 4096 \times (25088 + 1) = 4096 \times 25089 \approx 1.028 \times 10^8$ 。

约 1.03 亿($\approx 102.8M$) 个参数——就这一层。对比例题 1 的卷积层只有 760 个:全连接层没有参数共享,一展平就"参数爆炸"。这正是 VGG 138M 参数大半堆在 FC、而 GoogleNet/ResNet 索性去掉 FC 的原因。

经典考点:两个 3×3 为什么能替一个 5×5

把两个 3×3 卷积叠起来,第二层每个神经元透过第一层能"看到"输入的 5×5 区域——感受野等效于一个 5×5 卷积。但参数上(单通道单核):一个 $5 \times 5 = 25$ 个权重,两个 $3 \times 3 = 2 \times 9 = 18$ 个,更省;而且中间多插了一次非线性激活(ReLU),表达力更强。这就是 VGG"只用小核堆深"的核心论据——考简答题常问,记住"同感受野、更少参数、更多非线性"九个字。

自测题 2 · 池化尺寸

输入特征图 16×16 ,做 3×3 池化,步长 $s=1$, $p=0$ (重叠池化)。输出边长是多少?

- A. 13
- B. 14
- C. 15
- D. 16

▼ 答案与解释

答案:B 14

池化同样套 $(N - F)/s + 1 = (16 - 3)/1 + 1 = 13 + 1 = 14$ 。

易错点:这里 $s=1$ (重叠池化)而非常见的 $s=2$,所以尺寸只小一点点,不是减半。别一看"池化"就条件反射写"除以 2"——先看步长。

自测题 3 · 多层串联

输入 64×64 , 先过 **Conv**(3×3 , $p=1$, $s=1$), 再过 **Max Pool**(2×2 , $s=2$)。
输出边长是多少?

- A. 16
- B. 62
- C. 32
- D. 31

▼ 答案与解释

答案:C 32

一层一层来:

Conv 3×3 , $p1$, $s1$: $(64 - 3 + 2)/1 + 1 = 63 + 1 = 64$ ——配了 $p=1$, 尺寸不变。

Pool 2×2 , $s2$: $(64 - 2)/2 + 1 = 31 + 1 = 32$ ——减半。

陷阱:D 选项 31 是"忘了最后 +1"; B 62 是"卷积忘加 padding"。牢记卷积那步因 $p=1$ 保持 64 不变, 只有池化把它砍到 32。

串联计算不翻车的三条纪律

- ① 一层一行, 绝不心算跳步——上一层输出照抄进下一层输入。
- ② 先认"尺寸变不变": 卷积配 $p=(F-1)/2$ 就保尺寸, 池化($s=2$)必减半, $\text{stride}>1$ 的卷积也会缩。
- ③ +1 永远最后做, 除不尽向下取整——这两处是丢分重灾区。

全课完 → 12 讲微课到此收官——从像素、色彩、音频、压缩编码, 一路到检索与 CNN。接下来别再单点练了, 去做**整卷自测**: 先用 真题与考点 核对每类计算题的老师口径, 再上 模拟卷 掐表实战一遍。祝你稳过这 100 分。

